

Rapport de Projet : Classification des Radiographies Pulmonaires par Deep Learning

Ahmed Bennasser

12 octobre 2025

Résumé

Ce projet développe un système de classification des radiographies pulmonaires en quatre catégories : COVID, Normal, Lung Opacity et Viral Pneumonia. Le dataset initial présentant un déséquilibre significatif a été équilibré à 5000 images par classe via sous-échantillonnage et data augmentation. Trois architectures de deep learning ont été implémentées et comparées.

1 Introduction

1.1 Contexte

Le projet vise à classifier automatiquement les radiographies pulmonaires en quatre catégories distinctes pour assister le diagnostic médical.

1.2 Objectifs

- Développer un classifieur de radiographies pulmonaires
- Gérer le déséquilibre des données médicales
- Comparer les performances de différents modèles de deep learning

2 Données et Méthodologie

2.1 Description du Dataset

Le dataset initial présente la distribution suivante :

Classe	Nombre d'images
COVID	3,616
Viral Pneumonia	1,345
Normal	10,192
Lung Opacity	6,012

2.2 Problème de Déséquilibre

La classe Normal domine à 48% tandis que Viral Pneumonia ne représente que 6%, risquant de causer du sur-apprentissage.

2.3 Stratégie d'Équilibrage

- **Sous-échantillonnage** : Normal et Lung Opacity réduites à 5000 images
- **Augmentation de données** : COVID et Viral Pneumonia augmentées à 5000 images
- **Cible** : 5000 images par classe

2.4 Data Augmentation

Les transformations appliquées incluent :

```
transforms.Compose([
    transforms.RandomRotation(15),
    transforms.RandomHorizontalFlip(),
    transforms.RandomResizedCrop(224, scale=(0.8, 1.0)),
    transforms.ColorJitter(brightness=0.2, contrast=0.2),
    transforms.ToTensor()
])
```

2.5 Split des Données

Set	Nombre d'images
Train	14,000 (70%)
Validation	3,000 (15%)
Test	3,000 (15%)

3 Architectures des Modèles

3.1 Modèles Implémentés

1. **CNN_MLP** : Architecture développée from scratch
2. **EfficientNetV2-S** : Modèle pré-entraîné de torchvision
3. **ResNet-18** : Architecture résiduelle classique

3.2 Environnement Technique

- **GPU** : NVIDIA A100-SXM4-40GB
- **Bibliothèques** : PyTorch, torchvision, torchinfo
- **Prétraitement** : PIL, scikit-learn

4 Résultats

4.1 Distribution Finale

Après équilibrage, chaque classe contient 5000 images, soit 25% de la distribution totale.

4.2 Performance des Modèles

Les trois modèles ont été entraînés et évalués sur le jeu de test. Les métriques complètes (accuracy, precision, recall, F1-score) donne des bonnes résultats (plus de 90/100 en accuracy)

- * **CNN-MLP** a une accuracy 0.891 sur le test de 3000 images
- * **ResNet18** a une accuracy de 0.966 sur le test data
- * **EfficientNetV2-S** a une accuracy de 0.9633

5 Discussion

5.1 Gestion du Déséquilibre

L'approche d'équilibrage a permis de :

- Réduire le biais envers la classe majoritaire
- Améliorer la détection des classes minoritaires
- Prévenir le sur-apprentissage

5.2 Choix Architecturaux

La comparaison des trois architectures permet d'évaluer :

- L'efficacité d'un modèle custom (CNN_MLP)
- Les bénéfices du transfer learning (EfficientNet, ResNet)
- Le compromis performance/complexité

6 Conclusion

Le projet a mis en place un pipeline complet de classification d'images médicales, incluant :

- Un prétraitement robuste avec équilibrage des données
- L'implémentation de trois architectures de deep learning
- Une évaluation comparative des performances
- Une base solide pour des applications médicales assistées par IA

Les prochaines étapes incluent l'analyse fine des résultats et l'optimisation des hyper-paramètres.